

- 이 논문은 Microsoft Research의 Ross Girshick가 개발한 Fast R-CNN에 대한 연구임.
- 기존의 객체 탐지(Object Detection) 방식인 R-CNN과 SPPnet은 느리고 학습 구조가 복잡했음.

→ Fast R-CNN은 빠른 속도와 높은 정확도를 동시에 달성한 새로운 구조를 제안함.

1. Fast R-CNN이란?

- 이미지에서 객체를 인식하는 딥러닝 모델
 - 기존 방식(R-CNN)의 느림, 저장공간 낭비, 복잡한 학습을 해결함
 - RoI Pooling 기법을 도입해 다양한 크기의 객체 제안 영역도 고정 크기로 변환 가능
-

2. Fast R-CNN의 구조

- 입력: 전체 이미지 + 객체 제안 영역들(RoI)
- Conv Layer로 전체 이미지 처리 → Feature Map 생성
- 각 RoI에 대해 RoI Pooling 적용 → 고정 길이 feature vector 생성
- FC Layer 통과 후, 두 가지 출력 생성:

Softmax 분류 결과 (객체 종류)

Bounding Box 보정값 (위치 조정)

3. Fast R-CNN의 장점

a. 단일 단계 학습

→ Softmax와 BBox 회귀를 동시에 학습 (Multi-task Loss 사용)

b. 속도 매우 빠름

→ R-CNN보다 213배 빠르게 테스트 가능

c. 정확도 향상

→ PASCAL VOC 2012에서 mAP 66.9% 달성 (R-CNN은 66.0%)

d. 디스크 저장 불필요

→ Feature를 따로 저장할 필요 없이 학습 가능

4. Fast R-CNN 학습 방식

- 기존 모델(VGG16 등)을 활용해 사전학습된 가중치 사용
 - RoI Pooling을 통해 역전파(back-propagation)가 가능한 구조
 - SGD 미니배치 샘플링: 이미지 2장 선택 후, 각각 64개 RoI 추출
 - Loss 함수: 분류 + 위치 보정 동시 학습 (Multi-task Loss)
-

5. Fast R-CNN 성능

- a. VOC 2007/2010/2012 데이터셋에서 최고 성능 기록
 - b. 훈련 시간 9배 단축, 테스트 시간 213배 단축 (VGG16 기준)
 - c. Truncated SVD 기법 사용 시 추가 속도 향상 가능
 - d. Softmax만으로도 SVM보다 높은 성능
-

6. Fast R-CNN의 한계 및 과제

- a. 제안 영역(Region Proposal) 단계는 여전히 별도 실행 필요
- b. 실시간 객체 탐지에는 부족함 → 이후 Faster R-CNN, YOLO, SSD의 탄생 계기
- c. Dense Proposal 사용 시 정확도 하락 가능성 존재